

Cel

Przygotować się do interview – móc opisać narzędzia i rozwiązania analityczne, Big Data oraz AI, szczególnie w kontekście chmury Azure.

Najważniejsze Narzędzia (ogólnie + Azure)

Big Data / Analytics

Narzędzie	Opis
Azure Synapse Analytics	Platforma do kompleksowej analizy danych. Łączy możliwości przetwarzania danych SQL (hurtownia danych) oraz Spark (przetwarzanie Big Data). Umożliwia łatwe tworzenie raportów, transformacji danych i zapytań na dużą skalę – wszystko w jednym miejscu.
Databricks	Platforma analityczna i ML oparta na Apache Spark. Pozwala na szybkie przetwarzanie ogromnych zbiorów danych oraz tworzenie zaawansowanych modeli AI. Często używana w dużych projektach Data Science.
Azure Data Lake Storage (ADLS)	Skalowalna przestrzeń dyskowa zoptymalizowana pod dane nieustrukturyzowane (np. logi, pliki JSON, CSV). Służy jako „źródło prawdy” dla hurtowni i modeli ML.
Azure Data Factory (ADF)	Narzędzie do tworzenia pipeline’ów danych. Umożliwia integrację i transformację danych z różnych źródeł – lokalnych, chmurowych, API itp. Kluczowe narzędzie do ETL i ELT.
Power BI	Narzędzie do tworzenia dashboardów i raportów. Pozwala analizować dane z różnych źródeł i prezentować je w czytelny, wizualny sposób.
Kusto / Azure Data Explorer (ADX)	Narzędzie do bardzo szybkiej analizy dużych ilości logów i danych telemetrycznych (np. dane z aplikacji, serwerów, IoT). Umożliwia szybkie zapytania, wykrywanie trendów i anomalii.

AI / Machine Learning

Narzędzie	Opis
Azure Machine Learning (Azure ML)	Platforma do tworzenia, trenowania, monitorowania i wdrażania modeli ML. Umożliwia pracę zarówno no-code (GUI), jak i zaawansowane skrypty (Python, Jupyter). Zawiera m.in. eksperymenty, rejestr modeli, deployment REST API.
Cognitive Services	Zestaw gotowych API do wykrywania mowy, tłumaczenia tekstu, rozpoznawania obrazów, analizy sentymentu, ekstrakcji informacji itp. Nie trzeba pisać modelu od zera – wystarczy zintegrować API.
AutoML (Automated Machine Learning)	Funkcja w Azure ML, która automatycznie trenuje i testuje wiele modeli, wybierając najlepszy. Idealna dla osób, które nie chcą ręcznie budować modelu ML.
MLflow	Narzędzie do zarządzania eksperymentami ML. Pozwala śledzić parametry modeli, wersje kodu, metryki oraz przechowywać gotowe modele. Pomaga ogarnąć chaos przy większych projektach.
Responsible AI Dashboard	Narzędzie do sprawdzania, czy model ML nie ma biasu, czy jest uczciwy i zrozumiały. Pozwala przeanalizować, dlaczego model podjął daną decyzję – przydatne np. przy AI w finansach czy medycynie.

Przykład PoC: Wykrywanie anomalii na linii produkcyjnej (IoT)

Scenariusz

Zbieramy dane z czujników IoT z linii produkcyjnej – np. temperatury, ciśnienia, wibracji. Chcemy wykrywać anomalie, które mogą oznaczać potencjalne awarie maszyn, zanim do nich dojdzie.

Użyte Narzędzia (Azure)

- **IoT Hub** – odbiera dane z urządzeń IoT (np. maszyny na hali). To brama pomiędzy fizycznym światem a chmurą.
- **Azure Stream Analytics / Azure Functions** – służą do analizy danych w czasie rzeczywistym. Możemy np. natychmiast wysłać alert, jeśli czujnik wykryje niebezpieczne wartości.

- **Azure Data Lake / Azure Synapse** – przechowują dane historyczne. Możemy na nich trenować modele AI lub robić raporty.
- **Azure Machine Learning / AutoML** – na podstawie danych historycznych trenujemy model wykrywania anomalii.
- **Power BI** – tworzymy dashboardy pokazujące status maszyn, historię błędów, alerty itp.

Architektura PoC

rust

KopiujEdytuj

IoT Devices --> IoT Hub --> Stream Analytics --> Data Lake + Azure ML

|
Power BI dashboard

Architektura Big Data dla Rockstar Games

Cel

Wykrywanie i zapobieganie błędom w grze oraz analiza satysfakcji użytkowników – zarówno w czasie rzeczywistym (telemetria z gry), jak i offline (np. feedback z supportu).

Zalecane narzędzia (Azure stack)

Ingest (zbieranie danych)

- **Azure Event Hubs** – odbiera dane telemetryczne z gier: kliknięcia, zdarzenia, błędy, interakcje gracza.
- **Azure Data Factory** – pobiera dane z systemów wsparcia (np. zgłoszenia do supportu, opinie graczy), zwykle jako wsady/batch.

Storage

- **Data Lake Gen2** – składowanie danych surowych (z Event Hubs i Data Factory), które potem analizujemy.
- **Synapse Dedicated SQL Pools** – baza danych do szybkich zapytań SQL, np. do raportów i dashboardów.

Compute / Processing

- **Azure Synapse + Spark pools** – przetwarzanie sesji gry, analiza zachowań użytkowników.
- **Azure ML / AutoML** – budujemy modele ML, np. przewidujące rage quit, awarie, błędy w misjach.
- **Databricks (opcjonalnie)** – alternatywa dla Spark Synapse, przydatna przy zaawansowanych modelach ML i przetwarzaniu dużych ilości danych.

Monitoring & Viz

- **Power BI** – wizualizacje pokazujące np. najczęstsze błędy, statystyki graczy, jakość gry.
- **Azure Monitor + Kusto (ADX)** – analiza logów serwerów, performance gry, wykrywanie dziwnych spike'ów (np. masowe crashe).

Architektura

rust

KopiujeEdytuj

Telemetry/Game Logs --> Event Hubs --> Azure Data Lake

--> Synapse + Spark --> Feature Store / ML

Support Data -----> Data Factory -----|

ML Model Predictions --> Power BI (user satisfaction, bug trends)

Certyfikacje – Co warto ogarniać z materiałów?

DP-203 (Data Engineering)

- Architektura Lambda (real-time + batch), Medallion (bronze/silver/gold layers)
- Delta Lake – system plików wspierający ACID na data lake
- Partitioning, pipelines, copy data, data flow w ADF
- Bezpieczeństwo – RBAC, private endpoints, managed identities

DP-100 (AI + ML)

- Tworzenie eksperymentów w Azure ML
- Zarządzanie środowiskami treningowymi
- Deployment modeli jako REST API
- Śledzenie metryk, rejestracja i monitorowanie modeli

AI-102 (AI Solutions Architect)

- Cognitive Services (Vision, Text, Language)
- Tworzenie botów (Azure Bot Framework)
- Tworzenie i wdrażanie modeli AI z użyciem REST API
- Stosowanie Responsible AI – fairness, explainability, privacy