

Spark UI – Notatka

Spark UI to narzędzie webowe, które pozwala monitorować i analizować działanie aplikacji Spark. Składa się z kilku zakładek, z których każda dostarcza innego typu informacji:

1. Jobs

- Pokazuje wszystkie uruchomione i zakończone **zadania (jobs)**.
- Widać status (np. zakończone, trwające, nieudane), czas trwania, liczbę etapów (stages).
- Klikając na job, można zobaczyć, z jakich stages się składał.

2. Stages

- Pokazuje szczegóły dla każdego **etapu (stage)** joba.
- Zawiera dane o liczbie tasków, czasie trwania, liczbie przetworzonych danych.
- Można sprawdzić, czy wystąpiły błędy lub opóźnienia w konkretnych taskach.

3. Storage

- Pokazuje informacje o **przechowywaniu danych w pamięci** (np. cache).
- Widać jakie RDD/DataFrame'y zostały zapisane, ile miejsca zajmują i na ilu partycjach.
- Przydatne do sprawdzania efektywności cachowania danych.

4. Executors

- Informacje o **egzekutorach** (czyli procesach wykonujących taski).
- Widać liczbę tasków wykonanych przez każdego, wykorzystanie pamięci, czas działania.
- Można ocenić, czy wszystkie executory są równomiernie obciążone.

5. SQL / Dataframe

- Pokazuje szczegóły wykonania **zapytania SQL lub operacji na DataFrame**.
- Widać fizyczny plan wykonania zapytania oraz czasy trwania operacji.
- Pomocne do debugowania zapytań i optymalizacji wydajności.

Gdzie znajdziesz informację o dystrybucji danych?

- **Storage** – pokazuje rozkład danych w partycjach (ile danych przypada na każdą).
- **Executors** – pokazuje, jak dane są przetwarzane na poszczególnych executorach.
- **Stages** – pozwala zobaczyć, które taski były przypisane do jakich partycji.