

ZADANIE 1 – Kosztorys Lakehouse w Azure (na 1 rok)

Założenia:

- **Dane początkowe:** 10 TB
- **Przyrost miesięczny:** 200 GB → 2.4 TB rocznie
- **Razem po roku:** 12.4 TB
- **Usługi:**
 - Azure Storage Account (Hot/Archive tiers)
 - Azure Databricks (Premium Tier, z funkcją auto-scaling)
 - Azure Key Vault
 - Azure Data Factory
 - Azure SQL Server (PaaS – Azure SQL Database)

Usługa	Opis	Koszt roczny (EUR)
Storage Account	12.4 TB (Hot tier + część w Archive)	€1,200
Databricks	Premium Tier, 2 clusters (8h/dzień, 5 dni/tyg)	€14,000
Key Vault	10 000 operacji/miesiąc	€50
Data Factory	1 pipeline dziennie, 30 min przetwarzania, 1 IR	€1,200
Azure SQL	1x S2 DB (100 DTUs, 250 GB)	€900
SUMA		~€17,350 / rok

ZADANIE 2 – Delta Lake vs Iceberg

Cecha	Delta Lake	Apache Iceberg
Twórca	Databricks	Netflix
Kompatybilność	Spark, Databricks, Synapse, Snowflake	Spark, Trino, Flink, Snowflake

Format	Parquet	Parquet, Avro, ORC
Time Travel	✓ Tak	✓ Tak
Merge/upsert (ACID)	✓ Tak (MERGE INTO)	✓ Tak (nieco mniej optymalny)
Schema Evolution	✓ Dynamiczna	✓ Lepsza obsługa złożonych schematów
Silna integracja z ML	✓ Tak (Databricks MLflow, AutoML)	✗ Nie
Wydajność na Databricks	✓ Bardzo wysoka	✗ Średnia
Otwartość standardu	Pół-otwarty	✓ Całkowicie otwarty standard

Rekomendacje:

- **Delta Lake (na Databricks):**
 - Świetny wybór jeśli główną platformą jest **Azure Databricks**
 - Idealny przy ML, szybkim prototypowaniu, jobach ETL
 - Wysoka wydajność, stabilność, prostszy merge
- **Apache Iceberg:**
 - Lepszy wybór przy **multi-engine architecture** (Spark + Flink + Trino)
 - Silny nacisk na **otwarty standard, data sharing**
 - Lepszy przy bardziej złożonych schematach, heterogenicznych środowiskach

ZADANIE 3 – Krytyka architektury Medallion (20 punktów)

Medallion architecture (Bronze – Silver – Gold) ma zalety, ale też wady. Oto 20 krytycznych punktów:

N
r

Krytyka

- 1 **Złożoność wdrożenia** – 3 warstwy oznaczają więcej kodu ETL i testów.
- 2 **Opóźnienie danych** – przetwarzanie przez warstwy zwiększa latency.
- 3 **Powielanie danych** – dane są kopiowane między warstwami, co zwiększa koszty storage.
- 4 **Zwiększone koszty operacyjne** – więcej jobów = większe koszty Databricks/Spark.

- 5 **Przesadne separowanie logiki** – niektóre scenariusze nie wymagają aż 3
poziomów.
- 6 **Brak standaryzacji** – każdy projekt może inaczej definiować warstwy.
- 7 **Złożona konserwacja** – trudniej zarządzać wersjami danych i logiką konwersji.
- 8 **Niepotrzebne dla małych danych** – dla <1TB to nadmiarowy narzut.
- 9 **Ryzyko rozbieżności danych** – nieaktualne warstwy mogą wprowadzać błędy
analityczne.
- 1 **Zwiększony czas nauki** – nowe zespoły muszą uczyć się konwencji
0 trójwarstwowej.
- 1 **Duplikacja logiki biznesowej** – niektóre zasady powtarzają się w Silver i Gold.
- 1 **Wyzwania w CI/CD** – ciężiej testować i wdrażać zmiany w pipeline'ach.
- 2 **Problemy z lineage** – przy wielu transformacjach trudniej prześledzić dane.
- 1 **Gold warstwa bywa niepotrzebna** – czasem wystarczy Silver + metryki.
- 4 **Zwiększa dług techniczny** – przy braku automatyzacji ciężko to utrzymać.
- 1 **Silna zależność od konkretnego narzędzia (np. Databricks)**
- 6 **Problemy z real-time** – architektura lepiej działa w batchu niż w streamingu.
- 1 **Brak oficjalnego standardu** – nie ma jednej poprawnej definicji Medallion.
- 8 **Utrudnia prototypowanie** – dla prostych analiz staje się barierą.
- 1 **Trudność w rollbacku danych** – cofnięcie zmian w wielu warstwach jest
0 problematyczne.